

Кейс 7: построение аддитивной модели по мотивам теоремы Колмогорова

Пусть требуется восстановить неизвестную зависимость

$$y = f(x_1, \dots, x_p) + \varepsilon$$

где

$$x = (x_1, \dots, x_p) \in [0, 1]^p$$

а ε – случайный шум.

Теорема Колмогорова о представлении непрерывной функции утверждает, что любая непрерывная функция f на единичном кубе может быть представлена в виде суперпозиции непрерывных функций одного аргумента и операции сложения:

$$f(x_1, \dots, x_p) = \sum_{k=1}^{2p+1} h_k \left(\sum_{i=1}^p \varphi_{ik}(x_i) \right)$$

Эта теорема служит мотивацией для практических моделей, которые строят многомерную зависимость через композиции и суммы одномерных функций. В лабораторной работе используется вычислительно реализуемый частный случай – аддитивная модель

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p g_j(x_j)$$

Почему аддитивная модель полезна:

- значительно проще полной многомерной аппроксимации
- снимает часть проблемы «проклятия размерности»
- позволяет интерпретировать вклад каждого признака отдельно
- естественно обобщает линейную регрессию

Если положить

$$g_j(x_j) = \beta_j x_j$$

то получим обычную линейную регрессию:

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p \beta_j x_j$$

Каждая функция g_j представляется в конечном базисе:

$$g_j(t) = \sum_{m=1}^M a_{jm} \psi_m(t)$$

где $\psi_1, \dots, \psi_M$ – выбранные базисные функции.

Тогда модель имеет вид

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p \sum_{m=1}^M a_{jm} \psi_m(x_j),$$

то есть оказывается линейной по параметрам β_0 и a_{jm}

Без дополнительных ограничений представление не единственно: константу можно переносить между β_0 и отдельными функциями g_j .

Поэтому обычно вводят условия центрирования, например

$$\sum_{i=1}^n g_j(x_{ij}) = 0 \quad j = 1, \dots, p,$$

или

$$\int_0^1 g_j(t) dt = 0$$

Про функционал качества: пусть имеется обучающая выборка

$$X^\ell = \{(x_i, y_i)\}_{i=1}^\ell, \quad x_i = (x_{i1}, \dots, x_{ip})$$

Квадратичный функционал качества:

$$Q(\alpha, X^\ell) = \sum_{i=1}^\ell (g(x_i, \alpha) - y_i)^2$$

Для аддитивной модели после базисного разложения он принимает вид

$$Q(\theta) = \sum_{i=1}^\ell \left(y_i - \beta_0 - \sum_{j=1}^p \sum_{m=1}^M a_{jm} \psi_m(x_{ij}) \right)^2$$

Если ввести матрицу признаков, задача сводится к методу наименьших квадратов.

Задания для работы

1. Рассмотреть регрессионную задачу

$$y = f(x_1, \dots, x_p) + \varepsilon, \quad x_j \in [0, 1]$$

2. Подготовить обучающую и тестовую выборки
3. Нормировать признаки в интервал $[0, 1]$, если это требуется
4. Выбрать базис для функций g_j , например
 - полиномиальный базис $1, t, t^2, \dots, t^d$
 - тригонометрический базис
 - кусочно-линейные или кусочно-квадратичные функции
 - В-сплайны

5. Сформировать блочную матрицу признаков для аддитивной модели

6. Пусть

$$z_i = (1, \psi_1(x_{i1}), \dots, \psi_M(x_{i1}), \psi_1(x_{i2}), \dots, \psi_M(x_{ip}))$$

Тогда модель можно записать как

$$\hat{y}_i = z_i^T \theta$$

- (a) построить матрицу Z – таблица всех признаков, на которых обучается модель
- (b) оценить параметры по МНК
- (c) при необходимости реализовать ridge-регрессию

7. Чтобы сделать разложение однозначным, ввести центрирование:

$$\sum_{i=1}^{\ell} g_j(x_{ij}) = 0 \quad \forall j$$

- (a) выполнить центрирование компонент после обучения
- (b) скорректировать свободный член β_0

8. Сравнить с линейной моделью

$$\hat{y}_{\text{lin}} = \beta_0 + \sum_{j=1}^p \beta_j x_j$$

- (a) обучить линейную модель
- (b) сравнить её с аддитивной моделью по метрикам:

$$\text{MSE}, \quad \text{RMSE}, \quad R^2$$

9. Сравнить с полной нелинейной моделью. Рассмотреть более богатую модель, например, полиномиальную регрессию с попарными взаимодействиями:

$$\hat{y}_{\text{full}} = \beta_0 + \sum_j \beta_j x_j + \sum_{j \leq k} \beta_{jk} x_j x_k + \dots$$

- (a) обучить полиномиальную модель или другую гибкую модель сравнения
- (b) сравнить её с аддитивной моделью по качеству и числу параметров

10. Исследовать влияние числа базисных функций. Пусть на каждый признак берётся M базисных функций.

- (a) перебрать несколько значений M
- (b) построить графики зависимости ошибок на обучении и тесте от M
- (c) определить разумный диапазон сложности модели

11. После обучения восстановить функции

$$\hat{g}_j(t) = \sum_{m=1}^M \hat{a}_{jm} \psi_m(t)$$

как интерпретировать графики $\hat{g}_j$?

- (a) построить графики всех функций $\hat{g}_j$
- (b) сравнить их с истинными функциями, если данные синтетические

12. Использовать набор данных, где присутствуют зависимости между признаками

$$y = \sin(2\pi(x_1 + x_2)) + x_3 + \varepsilon$$

или

$$y = x_1 x_2 + x_3 + \varepsilon.$$

- (a) провести отдельный эксперимент на неаддитивных данных
- (b) сравнить качество аддитивной и более общей модели

Данные для работы

1. Синтетические аддитивные данные, например:

$$x_{ij} \sim U[0, 1], \quad j = 1, \dots, p$$

и

$$y_i = \sin(2\pi x_{i1}) + 0.5(x_{i2} - 0.5)^2 + \exp(-3x_{i3}) + \varepsilon_i$$

где

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

2. Синтетические неаддитивные данные, например:

$$y_i = \sin(2\pi(x_{i1} + x_{i2})) + 0.5x_{i3} + \varepsilon_i$$

или

$$y_i = x_{i1}x_{i2} + x_{i3} + \varepsilon_i$$

3. Реальные данные

Можно взять любой табличный набор данных для регрессии, в котором признаки можно привести к интервалу $[0, 1]$. Например:

- California Housing
- Energy Efficiency
- Airfoil Self-Noise
- другой небольшой регрессионный датасет