

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»**

Метрические методы регрессии

Исследовательская работа по дисциплине «Функциональный анализ»

Работа №6

Выполнил: Мирасов К.В. (гр. J3212)

Проверил: Ершов А.Р.

Содержание

1	Введение	2
2	Постановка задачи	2
3	Методы	3
3.1	Надарая–Ватсона, фиксированное окно	3
3.2	Переменное окно	3
3.3	Локально взвешенный МНК	3
3.4	Ядра	4
3.5	Подбор гиперпараметров	4
3.6	Робастная схема LOWESS	4
4	Данные и эксперимент	4
5	Результаты	5
5.1	Одномерная синтетика	5
5.2	Сравнение ядер	7
5.3	Реальные датасеты	8
5.4	Выбросы и робастность	9
5.5	Уровень загрязнения	11
5.6	Ядро против окна	12
6	Рефлексия по результатам	12
7	Выводы	13
8	Ссылка на репозиторий	13

1 Введение

Рассматривается задача непараметрической регрессии при гипотезе непрерывности: близким объектам соответствуют близкие ответы. В этой постановке не вводится конечномерная параметрическая модель зависимости, а значение регрессии в новой точке восстанавливается по локальному окружению обучающей выборки.

Цель работы состоит в реализации и исследовании метрических методов регрессии: оценки Надарая–Ватсона с фиксированным окном, оценки Надарая–Ватсона с переменным окном и робастной схемы LOWESS. Исследуется влияние формы ядра, ширины окна, числа соседей и робастного перевзвешивания на ошибку прогноза и устойчивость к выбросам.

Выполнены четыре группы экспериментов. Для одномерной синтетической задачи построены кривые сглаживания и LOO-ошибки. Для четырёх ядер получены оптимальные значения окна. На датасетах Diabetes и California Housing измерены MAE, RMSE и R^2 . Для загрязнённой выборки оценён порог, начиная с которого LOWESS становится предпочтительнее обычного сглаживания.

2 Постановка задачи

Постановка задачи

Дана обучающая выборка $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$, где $x_i \in \mathbb{R}^n, y_i \in \mathbb{R}$. Требуется построить оценку регрессии в точке x по расстояниям $\rho(x, x_i)$, сравнить фиксированное и переменное окно, подобрать h, k и ядро K , затем исследовать робастное перевзвешивание LOWESS при наличии выбросов.

Для фиксированного окна используется оценка Надарая–Ватсона

$$a(x; X^\ell, h) = \frac{\sum_{i=1}^\ell y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^\ell K\left(\frac{\rho(x, x_i)}{h}\right)}, \quad (1)$$

где $K(r)$ является ядром, $h > 0$ задаёт ширину окна, а ρ обозначает евклидово расстояние после стандартизации признаков.

Переменное окно задаётся расстоянием до ближайшего объекта с номером $k + 1$:

$$h(x) = \rho(x, x_{(k+1)}), \quad a(x; X^\ell, k) = \frac{\sum_{i=1}^\ell y_i K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)}{\sum_{i=1}^\ell K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)}. \quad (2)$$

Такое окно расширяется в разреженных областях и сужается там, где объектов много.

Оценка (1) может быть получена из локально взвешенного метода наименьших квадратов при локальной модели $f(x_i) \approx \theta$:

$$Q(\theta; x) = \sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right) (\theta - y_i)^2 \rightarrow \min_{\theta}. \quad (3)$$

LOWESS вводит объектные веса γ_i . На итерации вычисляются LOO-прогнозы и остатки, затем веса обновляются правилом

$$a_i = \frac{\sum_{j \neq i} y_j \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}{\sum_{j \neq i} \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}, \quad \varepsilon_i = |a_i - y_i|, \quad \gamma_i = \tilde{K}\left(\frac{\varepsilon_i}{6_j \varepsilon_j}\right). \quad (4)$$

В качестве метрик качества используются MAE, RMSE и R^2 . Гиперпараметры на синтетике подбираются по LOO-RMSE, на реальных данных применяется тот же критерий на обучающей части после train/test-разбиения.

3 Методы

3.1 Надарая–Ватсона, фиксированное окно

В фиксированном варианте вес объекта x_i равен $w_{i(x)} = K\left(\frac{\rho(x, x_i)}{h}\right)$. Тогда (1) является нормированным взвешенным средним ответов. Малое h уменьшает смещение, но повышает разброс из-за малой эффективной окрестности. Большое h стабилизирует оценку, но сглаживает локальные изменения функции.

Реализация использует матрицу попарных расстояний и нормировку строк матрицы весов. Для финитных ядер при нулевой сумме весов применяется ближайший сосед как численная защита, что не меняет результаты на выбранных сетках гиперпараметров и сохраняет корректность на постоянных данных.

3.2 Переменное окно

В адаптивной оценке ширина окна определяется локальной плотностью обучающих объектов. При одинаковом k плотная область получает малое $h(x)$, а разреженная область получает более широкое окно. Поэтому k задаёт не абсолютный масштаб расстояний, а эффективное число соседей, участвующих в оценке.

Для LOO-подбора объект x_i исключается из собственной окрестности: диагональ матрицы весов обнуляется. Это эквивалентно пересчёту прогноза $a_{-i}(x_i)$ без переобучения модели и позволяет строить кривые ошибки по h и k за один проход по сетке.

3.3 Локально взвешенный МНК

Пусть $w_i = K\left(\frac{\rho(x, x_i)}{h}\right)$. Функционал (3) имеет производную

$$\frac{dQ(\theta; x)}{d\theta} = 2 \sum_{i=1}^{\ell} w_i (\theta - y_i). \quad (5)$$

Условие стационарности даёт

$$\theta^* \sum_{i=1}^{\ell} w_i = \sum_{i=1}^{\ell} w_i y_i, \quad \theta^* = \frac{\sum_{i=1}^{\ell} w_i y_i}{\sum_{i=1}^{\ell} w_i}. \quad (6)$$

Полученная оценка совпадает с формулой Надарая–Ватсона (1). Следовательно, ядерное сглаживание в этой модели является решением локальной вариационной задачи с константной аппроксимацией функции в окрестности точки x .

3.4 Ядра

В работе сравниваются четыре ядра:

- гауссовское: $K(r) = \exp\left(-\frac{r^2}{2}\right)$
- Епанечникова: $K(r) = \frac{3}{4}(1 - r^2)_+^2$
- кватрическое: $K(r) = \frac{15}{16}(1 - r^2)_+^3$
- треугольное: $K(r) = (1 - r)_+$

Здесь $(u)_+ = \max(u, 0)$. В оценке (1) общий множитель ядра сокращается, поэтому существенна форма убывания веса, а не нормировочная константа.

3.5 Подбор гиперпараметров

Для фиксированного окна строится логарифмическая сетка значений h , основанная на квантилях положительных попарных расстояний. Для переменного окна строится целочисленная сетка k . Критерий выбора имеет вид

$$\text{LOO-RMSE}(\lambda) = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - a_{-i}(x_i; \lambda))^2}, \quad (7)$$

где λ обозначает h или k . Исключение объекта i реализуется обнулением диагонали весовой матрицы.

3.6 Робастная схема LOWESS

LOWESS начинается с $\gamma_i = 1$ для всех объектов. Далее последовательно вычисляются LOO-прогнозы по (4), остатки ε_i , медианная шкала ошибок и новые веса. В экспериментах использовано 5 итераций. Для ядра перевзвешивания применяется кватрическая функция, поэтому точки с большим относительным остатком получают веса, близкие к нулю.

4 Данные и эксперимент

Синтетическая выборка состоит из 180 точек $x \in [0, 2\pi]$ и ответов $y = \sin x + \varepsilon$, где ε имеет нормальное распределение с нулевым средним и стандартным отклонением 0,12. Для визуализации используется равномерная сетка из 420 точек.

Для робастного эксперимента та же синтетическая схема загрязняется крупными сдвигами ответа. В основной таблице доля выбросов равна 15%. Для оценки порога загрязнения рассматриваются доли 0%, 5%, 10%, 15%, 20% и 30%, каждая точка усредняется по 4 seed.

В реальных данных используются Diabetes и California Housing. Diabetes содержит 442 объекта и используется полностью. Для California Housing взята фиксированная подвыборка из 1200 объектов, потому что вычисление матрицы расстояний имеет сложность $O(\ell^2)$. Признаки стандартизируются по обучающей части вручную на numpy. Разбиение train/test выполняется в пропорции 70/30 при seed 42.

5 Результаты

5.1 Одномерная синтетика

На Рис. 1 показаны истинная функция и наблюдения. Видно, что шумовая компонента мала относительно амплитуды синуса, поэтому задача подходит для анализа компромисса смещения и разброса.




Рис. 1. Одномерная синтетическая задача $y = \sin x + \varepsilon$: истинная функция и наблюдения

На Рис. 2 сопоставлены три значения h : малое, выбранное по LOO и большое. Малое окно повторяет шумовые колебания, большое окно сглаживает пики синуса. LOO-оптимум $h = 0,143$ находится между этими режимами.




Рис. 2. Прогноз Надарая–Ватсона при разных значениях ширины окна h

Кривые на Рис. 3 демонстрируют U-образную зависимость ошибки от h . Минимум RMSE достигается при $h = 0,143$, а рост ошибки при уходе от оптимума объясняет доминирующую роль масштаба окна.




Рис. 3. Зависимость LOO-ошибки (MAE и RMSE) от ширины окна h

Для переменного окна Рис. 4 показывает оптимум при $k = 12$. При слишком малом k оценка неустойчива, при слишком большом k возникает переусреднение.




Рис. 4. Зависимость ошибки от числа соседей k для переменного окна

5.2 Сравнение ядер

Формы ядер приведены на Рис. 5. Гауссовское ядро имеет бесконечный носитель, остальные ядра финитны и зануляют объекты вне единичного радиуса.




Рис. 5. Формы рассматриваемых ядер $K(r)$

На Рис. 6 видно, что для каждого ядра существует свой оптимальный масштаб h . После подбора окна различия между лучшими LOO-RMSE малы.




Рис. 6. Сравнение ядер по LOO-ошибке в зависимости от h

Ядро	Лучшее h	LOO-RMSE
Треугольное	0,324	0,1317
Гауссовское	0,143	0,1317
Епанечникова	0,324	0,1318
Квартическое	0,371	0,1318

Табл. 1. Лучшие гиперпараметры по ядрам

Вывод

Табл. 1 показывает, что после LOO-подбора окна все четыре ядра дают LOO-RMSE около 0,132. Различие между формами ядер существенно меньше, чем ошибка от неудачного выбора h .

5.3 Реальные датасеты

Табл. 2 содержит качество трёх методов на отложенной тестовой части. На Diabetes переменное окно снижает RMSE с 54,9 до 54,1. На California Housing снижение RMSE составляет с 0,719 до 0,682, что согласуется с неоднородной плотностью данных и разными локальными масштабами признакового пространства.

Датасет	Метод	MAE	RMSE	R^2
Diabetes	NW фиксированное окно	43,6	54,9	0,442
Diabetes	NW переменное окно	42,7	54,1	0,457
Diabetes	LOWESS	43,3	54,9	0,442
California Housing	NW фиксированное окно	0,507	0,719	0,563
California Housing	NW переменное окно	0,477	0,682	0,606
California Housing	LOWESS	0,480	0,706	0,577

Табл. 2. Качество на реальных датасетах

5.4 Выбросы и робастность

На Рис. 7 показана выборка с 15% выбросов. Обычная адаптивная ядерная регрессия смещается к загрязнённым точкам, тогда как LOWESS после перевзвешивания остаётся близким к истинной функции.




Рис. 7. Сравнение прогноза обычной ядерной регрессии и LOWESS при наличии выбросов

Робастные веса на Рис. 8 показывают механизм подавления выбросов: большая часть загрязнённых объектов получает веса около нуля, а обычные наблюдения сохраняют положительный вклад.




Рис. 8. Робастные веса γ_i после стабилизации LOWESS

Кривые до и после перевзвешивания приведены на Рис. 9. Перевзвешивание устраняет локальные деформации, вызванные выбросами, без изменения локального масштаба k .




Рис. 9. Кривые прогноза до и после робастного перевзвешивания

Распределение абсолютных остатков на Рис. 10 подтверждает тот же эффект: медиана и верхний квартиль ошибки у LOWESS заметно ниже.




Рис. 10. Распределение остатков по объектам для NW и LOWESS

Метод	MAE	RMSE	R^2
NW переменное окно	0,308	0,425	0,638
LOWESS	0,0468	0,0552	0,994

Табл. 3. Устойчивость к выбросам на чистом тесте

Вывод

Табл. 3 показывает, что при загрязнении 15% объектов RMSE на чистом тесте уменьшается с 0,425 для обычного сглаживания до 0,055 для LOWESS. Робастное перевзвешивание в этом режиме является определяющим фактором качества.

5.5 Уровень загрязнения

Рис. 11 показывает зависимость RMSE от доли выбросов. При отсутствии выбросов обычное сглаживание имеет RMSE 0,052, а LOWESS 0,055. Начиная с 5% загрязнения, LOWESS становится лучше: RMSE составляет 0,064 против 0,312 у обычного сглаживания.




Рис. 11. Зависимость RMSE на чистом тесте от доли выбросов для NW и LOWESS

5.6 Ядро против окна

Чувствительность к окну и ядру приведена на Рис. 12. Размах LOO-RMSE при варьировании h равен 0,534, тогда как размах при смене ядра в фиксированном масштабе равен 0,00468. Отношение размахов составляет 114.




Рис. 12. Чувствительность ошибки к выбору ядра и к выбору ширины окна

6 Рефлексия по результатам

Первый исследовательский вопрос касается относительной роли ядра и ширины окна. По Рис. 12 влияние h доминирует: неудачный масштаб меняет LOO-RMSE на 0,534, а смена ядра при согласованном масштабе меняет ошибку лишь на 0,00468. Следовательно, первичным гиперпараметром является окно, а ядро имеет вторичный эффект после подбора масштаба.

Второй вопрос касается преимущества переменного окна. Табл. 2 показывает выигрыш адаптивного окна на обоих реальных датасетах, особенно на California Housing. Это ожидаемо для неоднородной плотности объектов и многомерных признаков: фиксированный радиус либо захватывает слишком мало соседей в разреженных областях, либо чрезмерно усредняет плотные области.

Третий вопрос касается порога загрязнения. По Рис. 11 LOWESS начинает выигрывать с доли выбросов 5%. При 0% загрязнения робастное перевзвешивание не требуется и слегка уступает обычному сглаживанию, но уже при 5% резко уменьшает RMSE. При 10-30% загрязнения разрыв сохраняется, поскольку выбросы получают малые веса γ_i .

7 Выводы

Реализованы с нуля четыре ядра, евклидовы расстояния, оценка Надарая–Ватсона с фиксированным и переменным окном, LOO-подбор h и k , а также итерационная схема LOWESS. Проверки в ноутбуке подтверждают нормировку весов, нулевую диагональ LOO и сохранение константы.

Эксперименты показывают, что ширина окна влияет на качество сильнее выбора ядра. После подбора h все рассмотренные ядра дают почти одинаковую LOO-RMSE на синтетике. Переменное окно целесообразно использовать при неоднородной плотности данных, что подтверждено результатами на Diabetes и California Housing. LOWESS оправдан при наличии выбросов: найденный порог выигрыша равен 5% загрязнения обучающей выборки.

8 Ссылка на репозиторий

<https://github.com/mezgou/itmo-functional-analysis-course>