

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО»**

Аддитивная модель по мотивам теоремы Колмогорова

Исследовательская работа по дисциплине «Функциональный анализ»

Работа №7

Выполнил: Мирасов К.В. (гр. J3212)

Проверил: Ершов А.Р.

Содержание

1	Введение	2
2	Постановка задачи	2
3	Методы	3
3.1	Аддитивная модель и связь с теоремой Колмогорова	3
3.2	Базисные разложения	3
3.3	Блочная матрица, МНК и ridge	4
3.4	Центрирование и идентифицируемость	5
3.5	Модели сравнения	5
3.6	Протокол эксперимента	5
4	Данные и эксперимент	5
5	Результаты	6
5.1	Синтетические аддитивные данные	6
5.2	Сравнение моделей	7
5.3	Влияние числа базисных функций	8
5.4	Реальный датасет	9
5.5	Неаддитивные данные	9
6	Рефлексия по результатам	10
7	Выводы	11
8	Ссылка на репозиторий	11

1 Введение

Рассматривается задача восстановления зависимости $y = f(x_1, \dots, x_p) + \varepsilon$ на единичном кубе $[0, 1]^p$ по конечной обучающей выборке. Прямое построение полной многомерной аппроксимации быстро становится неустойчивым при росте числа признаков, поэтому полезны модели, которые используют одномерные функции и сохраняют интерпретируемость вклада признаков.

Теорема Колмогорова о представлении непрерывной функции задаёт общую мотивацию: многомерная непрерывная функция может быть представлена через суперпозиции функций одного аргумента и сложения. В работе используется вычислительно простой частный случай этой идеи, аддитивная модель. Она не претендует на полноту теоремы Колмогорова, но даёт линейную по параметрам задачу после выбора базиса.

Цель работы состоит в построении аддитивной регрессионной модели, оценке параметров по МНК и ridge, введении центрирования для идентифицируемости, сравнении с линейной и полной полиномиальной моделями, а также в проверке поведения на данных с взаимодействиями. Эксперименты проведены на синтетических аддитивных данных, реальном табличном датасете Diabetes и синтетической неаддитивной задаче.

2 Постановка задачи

Постановка задачи

Дана выборка $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$, где $x_i = (x_{i1}, \dots, x_{ip}) \in [0, 1]^p$, а $y_i = f(x_i) + \varepsilon_i$. Требуется построить аддитивную оценку $\hat{f}$, сформировать блочную матрицу признаков, оценить параметры по МНК и ridge, обеспечить однозначность разложения центрированием, сравнить качество с линейной и полной полиномиальной моделями и исследовать ограничение аддитивности на данных с взаимодействиями.

Аддитивная модель имеет вид

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p g_j(x_j). \quad (1)$$

Каждая одномерная компонента представляется в конечном базисе:

$$g_j(x_j) = \sum_{m=1}^M a_{jm} \psi_m(x_j). \quad (2)$$

После подстановки получается линейная по параметрам форма

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p \sum_{m=1}^M a_{jm} \psi_m(x_j). \quad (3)$$

Параметрический вектор обозначается через $\theta = (\beta_0, \{a_{jm}\})$. Для объекта x_i строка матрицы признаков задаётся как

$$z_i = (1, \psi_1(x_{i1}), \dots, \psi_{M(x_{i1})}, \dots, \psi_1(x_{ip}), \dots, \psi_{M(x_{ip})}). \quad (4)$$

Тогда $\hat{y}_i = z_i^T \theta$, а вся обучающая задача записывается через матрицу Z .

Квадратичный функционал качества равен

$$Q(\theta) = \sum_{i=1}^{\ell} \left(y_i - \beta_0 - \sum_{j=1}^p \sum_{m=1}^M a_{jm} \psi_m(x_{ij}) \right)^2. \quad (5)$$

Без дополнительных ограничений разложение не единственно: постоянную часть можно переносить между β_0 и компонентами g_j . Поэтому вводится условие

$$\sum_{i=1}^{\ell} g_j(x_{ij}) = 0, \quad j = 1, \dots, p. \quad (6)$$

Качество измеряется метриками MSE, RMSE и R^2 на отложенной тестовой выборке.

3 Методы

3.1 Аддитивная модель и связь с теоремой Колмогорова

Общая формула суперпозиции в теореме Колмогорова записывается как

$$f(x_1, \dots, x_p) = \sum_{k=1}^{2p+1} h_k(\sum_{i=1}^p \varphi_{ik}(x_i)). \quad (7)$$

Эта конструкция показывает, что одномерные функции могут быть достаточным строительным материалом для представления многомерных зависимостей. В практической части рассматривается более узкая модель (1), где внешние функции и внутренние суммы заменены прямой суммой покомпонентных эффектов.

Преимущество такого ограничения состоит в размерности параметров. При фиксированном M аддитивная модель имеет $1 + pM$ параметров. Полная полиномиальная модель с взаимодействиями добавляет смешанные мономы, поэтому число параметров растёт существенно быстрее. Аддитивная модель также сохраняет графики $\hat{g}_{j(t)}$ как интерпретируемые частные зависимости.

3.2 Базисные разложения

В ноутбуке реализованы три семейства базисов. Полиномиальный базис использует столбцы $t, t^2, \dots, t^M$. Тригонометрический базис чередует $\sin(2\pi kt)$ и $\cos(2\pi kt)$. Основным выбран кубический В-сплайновый базис на равномерных узлах с краевой кратностью 4. Он локален, устойчив к умеренному увеличению M и удобен для восстановления гладких компонент.

На Рис. 1 показаны функции $\psi_{m(t)}$ для основного разложения. Локальность В-сплайнов означает, что изменение отдельного коэффициента влияет на ограниченную часть интервала, в отличие от глобальных полиномов.




Рис. 1. Базисные функции $\psi_{m(t)}$ выбранного разложения

3.3 Блочная матрица, МНК и ridge

Матрица Z состоит из столбца единиц и p блоков по M столбцов. Каждый блок соответствует одному признаку и содержит значения выбранного одномерного базиса. Структура такой матрицы показана на Рис. 2.




Рис. 2. Блочная структура матрицы признаков Z

Оценка МНК записывается в стандартной форме

$$\hat{\theta} = (Z^T Z)^{-1} Z^T y, \quad (8)$$

если матрица невырождена. В реализации используется `numpy.linalg.lstsq`, что корректно обрабатывает возможную линейную зависимость столбцов. Для устойчивости при больших M используется `ridge`:

$$\hat{\theta}_\lambda = (Z^T Z + \lambda I')^{-1} Z^T y. \quad (9)$$

Матрица I' совпадает с единичной, кроме первого диагонального элемента. Он равен нулю, поэтому свободный член β_0 не штрафуются.

3.4 Центрирование и идентифицируемость

Для каждого признака j и базисной функции m вычисляется обучающее среднее

$$|(\psi)_{jm} = \frac{1}{\ell} \sum_{i=1}^{\ell} \psi_{m(x_{ij})}. \quad (10)$$

В матрицу Z включаются центрированные столбцы $\psi_{m(x_{ij})} - |(\psi)_{jm}$. Тогда для любой оценки коэффициентов выполняется

$$\sum_{i=1}^{\ell} \sum_{m=1}^M a_{jm} (\psi_{m(x_{ij})} - |(\psi)_{jm}) = 0, \quad (11)$$

что даёт условие (6). При переходе от нецентрированной записи к центрированной свободный член корректируется как

$$\beta_0^c = \beta_0 + \sum_{j=1}^p \sum_{m=1}^M a_{jm} |(\psi)_{jm}. \quad (12)$$

В ноутбуке центрирование выполняется сразу при построении матрицы, поэтому общий уровень автоматически уходит в β_0 .

3.5 Модели сравнения

Линейная модель имеет вид

$$\hat{y}_{\text{lin}} = \beta_0 + \sum_{j=1}^p \beta_j x_j. \quad (13)$$

Она является частным случаем аддитивной модели при $g_{j(t)} = \beta_j t$. Полная полиномиальная модель строится с помощью `PolynomialFeatures`: на синтетической аддитивной задаче использована степень 5, на Diabetes и неаддитивной задаче степень 2. Вторая модель включает взаимодействия, поэтому способна описывать выражения вида $x_1 x_2$.

3.6 Протокол эксперимента

Синтетические признаки генерируются сразу в $[0, 1]$. Для реального датасета применяется min-max нормировка, обученная только на train. Разбиение train/test фиксируется seed 42. Значение λ выбирается по внутренней валидационной части обучающей выборки из сетки $0, 10^{-6}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1$. Для влияния сложности перебирается $M = 4, \dots, 18$.

4 Данные и эксперимент

Синтетическая аддитивная задача задаётся формулой

$$y = \sin(2\pi x_1) + 0.5(x_2 - 0.5)^2 + \exp(-3x_3) + \varepsilon, \quad \varepsilon \sim N(0, 0.08^2). \quad (14)$$

Использовано 900 объектов и три признака. Истинные компоненты центрируются по обучающей выборке, чтобы их можно было сопоставлять с $\hat{g}_j$.

Реальный эксперимент использует датасет Diabetes из scikit-learn: 442 объекта, 10 числовых признаков и непрерывный целевой показатель. Этот набор выбран как небольшой табличный регрессионный датасет, который не требует сетевой загрузки и воспроизводится в стандартной поставке sklearn.

Неаддитивная задача задаётся функцией

$$y = x_1 x_2 + x_3 + \varepsilon, \quad \varepsilon \sim N(0, 0.08^2). \quad (15)$$

Произведение $x_1 x_2$ не представляется суммой функций отдельных аргументов, поэтому этот эксперимент проверяет границу применимости аддитивного класса.

5 Результаты

5.1 Синтетические аддитивные данные

Истинные центрированные компоненты приведены на Рис. 3. Первая компонента имеет осциллирующий вид, вторая является слабой квадратичной поправкой, третья задаёт монотонное экспоненциальное убывание.




Рис. 3. Истинные аддитивные компоненты $g_{j(t)}$ синтетической задачи

На Рис. 4 восстановленные компоненты сопоставлены с истинными. Форма синуса и экспоненты восстанавливается без заметного смещения. Квадратичная компонента имеет меньшую амплитуду, поэтому её оценка визуальнее более чувствительна к шуму, но знак кривизны сохраняется.




Рис. 4. Восстановленные компоненты $\hat{g}_{j(t)}$ и истинные функции

Вывод

Центрированные графики $\hat{g}_j$ дают интерпретируемую декомпозицию прогноза. Встроенная проверка ноутбука даёт максимальную абсолютную сумму компонент на обучении $7,99 \cdot 10^{-15}$, что численно подтверждает условие идентифицируемости.

5.2 Сравнение моделей

Табл. 1 показывает качество трёх моделей на синтетических и реальных данных. На аддитивной синтетике линейная модель имеет RMSE 0,421 и $R^2 = 0,686$, поскольку не описывает синусоидальную и экспоненциальную компоненты. Аддитивная модель снижает RMSE до 0,0781 при 37 параметрах. Полная полиномиальная модель даёт сопоставимое качество, RMSE 0,0804, но использует 56 параметров.

Датасет	Модель	MSE	RMSE	R^2	Параметры
Синтетические аддитивные	Линейная	0,178	0,421	0,686	4
Синтетические аддитивные	Аддитивная	0,00610	0,0781	0,989	37
Синтетические аддитивные	Полная полиномиальная	0,00646	0,0804	0,989	56
Diabetes	Линейная	2848,31	53,37	0,485	11
Diabetes	Аддитивная	2824,53	53,15	0,489	81
Diabetes	Полная полиномиальная	3183,76	56,42	0,424	66

Табл. 1. Сравнение моделей на аддитивных и реальных данных

То же соотношение по синтетике показано на Рис. 5. Аддитивная модель практически достигает качества полной полиномиальной аппроксимации, но остаётся покомпонентной и требует меньше параметров.




Рис. 5. Сравнение линейной, аддитивной и полной моделей по качеству

На Diabetes разница между линейной и аддитивной моделями меньше: RMSE уменьшается с 53,37 до 53,15. Полная полиномиальная модель второй степени ухудшает качество до RMSE 56,42, что указывает на переусложнение при ограниченном размере выборки.

5.3 Влияние числа базисных функций

На Рис. 6 показана зависимость train и test RMSE от числа В-сплайнов на признак. При малом M модель имеет повышенное смещение. При росте M обучающая ошибка снижается, а тестовая ошибка после минимума меняется слабо. Минимум в данном разбиении достигается при $M = 6$, а диапазон от 5 до 12 даёт близкое качество.




Рис. 6. Ошибки на обучении и тесте в зависимости от числа базисных функций M

Базис	M	λ	RMSE test	R^2 test
Полиномиальный	12	10^{-6}	0,0777	0,989
Тригонометрический	12	0	0,118	0,975
В-сплайны	12	0,1	0,0781	0,989

Табл. 2. Сравнение базисов при сопоставимом числе функций

Табл. 2 показывает, что полиномиальный базис и В-сплайны дают близкие тестовые ошибки, 0,0777 и 0,0781. Тригонометрический базис хуже на этой задаче, потому что в целевой функции одновременно присутствуют периодическая, квадратичная и экспоненциальная компоненты. Основным базисом оставлены В-сплайны из-за локальности и устойчивой интерпретации компонент.

Вывод

Увеличение M снижает смещение только до определённого уровня. После этого качество контролируется шумом и регуляризацией, поэтому разумно выбирать умеренное M , а не максимальное значение сетки.

5.4 Реальный датасет

Прогноз аддитивной модели на тестовой части Diabetes показан на Рис. 7. Точки концентрируются вокруг диагонали, но разброс остаётся заметным. Это согласуется с умеренным значением $R^2 = 0,489$ из Табл. 1.




Рис. 7. Прогноз против факта на тестовой выборке реального датасета

Результат на Diabetes показывает, что аддитивность может быть конкурентной даже без явных взаимодействий, но выигрыш над линейной моделью зависит от выраженности нелинейных покомпонентных эффектов. В этой выборке аддитивная модель улучшает RMSE лишь на 0,22, поэтому практический вывод является осторожным.

5.5 Неаддитивные данные

В неаддитивном эксперименте истинная функция содержит взаимодействие $x_1 x_2$. Рис. 8 показывает поверхность и остатки моделей на сетке при фиксированном $x_3 = 0,5$. У аддитивной модели остаток имеет регулярную структуру по плоскости (x_1, x_2) , что соответствует пропущенному взаимодействию. У полной полиномиальной модели остаток существенно слабее.




Рис. 8. Аддитивная и полная модели на неаддитивных данных

Модель	MSE	RMSE	R^2	Параметры
Аддитивная	0,0125	0,112	0,905	37
Полная полиномиальная	0,00553	0,0744	0,958	10

Табл. 3. Аддитивная против полной модели на неаддитивных данных

Вывод

Табл. 3 фиксирует ограничение класса: при наличии существенного взаимодействия полная модель снижает RMSE с 0,112 до 0,0744 и повышает R^2 с 0,905 до 0,958. Аддитивная модель остаётся устойчивой, но систематически проигрывает модели с произведением признаков.

6 Рефлексия по результатам

Эксперименты подтверждают две стороны аддитивного подхода. На синтетической задаче, где истинная функция действительно является суммой одномерных компонент, модель восстанавливает форму g_j и почти достигает качества полной полиномиальной регрессии. При этом число параметров растёт как $1 + pM$, а восстановленные функции можно анализировать отдельно.

Центрирование является не технической деталью, а условием интерпретации. Без него константа компоненты могла бы быть перенесена в β_0 или в любую другую компоненту, поэтому графики $\hat{g}_j$ не были бы однозначны. Построение центрированных блоков делает сумму каждой компоненты на обучении нулевой и фиксирует общий уровень в свободном члене.

Роль регуляризации проявляется при увеличении M и на реальном датасете. В-сплайновые блоки могут содержать близкие или зависимые столбцы, поэтому ridge без штрафа на β_0 стабилизирует коэффициенты и сохраняет корректный уровень прогноза. Значение λ выбиралось по валидации, что уменьшает риск подгонки под один train/test-разрез.

Ограничение модели видно на неаддитивных данных. Если целевая функция содержит взаимодействия, графики отдельных g_j уже не могут полностью описать поверхность. В таком случае требуется модель с произведениями признаков, ядерный метод, деревья решений или другое расширение, явно учитывающее совместные эффекты.

7 Выводы

Аддитивная модель построена как линейная по параметрам задача МНК после выбора одномерного базиса. Реализованы полиномиальный, тригонометрический и В-сплайновый базисы, блочная матрица Z , МНК, ridge без штрафа на свободный член, центрирование и восстановление компонент.

На синтетических аддитивных данных аддитивная модель получила RMSE 0,0781 и $R^2 = 0,989$, что лучше линейной модели и сопоставимо с полной полиномиальной моделью при меньшем числе параметров. Восстановленные компоненты согласуются с истинными функциями. На Diabetes улучшение над линейной моделью оказалось небольшим, но направление метрик сохранилось.

Эксперимент с функцией $x_1x_2 + x_3$ показывает границу применимости: полная модель с взаимодействием выигрывает у аддитивной по MSE, RMSE и R^2 . Поэтому аддитивная модель целесообразна, когда ожидаются покомпонентные нелинейности, а при сильных взаимодействиях требуется расширенный класс моделей.

8 Ссылка на репозиторий

<https://github.com/mezgou/itmo-functional-analysis-course/>